

Predicción de calificaciones a partir de hábitos de estudio y características académicas

Manuel Bajos Rivera

Abstract—En este documento se estudia la posibilidad de predecir la calificación obtenida por un estudiante en un examen final a partir de diferentes datos académicos y hábitos. Para ello se utiliza el conjunto de datos Student Performance & Study Habits Dataset obtenido del kaggle, compuesto por 1,000 registros y 12 variables relacionadas, como horas de sueño, hábitos académicos, condiciones del entorno y rendimiento previo.

El estudio se enfoca exclusivamente en un problema de regresión, utilizando como variable a predecir la calificación del examen final (*final_exam_score*). Se implementó manualmente un modelo de regresión lineal optimizado mediante el algoritmo de gradiente descendiente. Posteriormente, se realizaron dos implementaciones adicionales utilizando la librería de Scikit-learn: un *DecisionTreeRegressor* y un *RandomForestRegressor*, ambos evaluados bajo el mismo procedimiento de partición aleatoria de los datos en conjuntos de entrenamiento, validación y prueba, y el mismo esquema de estandarización.

Los resultados muestran que el modelo de gradiente descendiente implementado manualmente obtuvo un R^2 de 0.6455 sobre el conjunto de prueba, el desempeño más alto entre los tres modelos evaluados. El árbol de decisión, entrenado sin restricción sobre el número mínimo de observaciones por hoja, alcanzó un R^2 de 1.00 sobre el conjunto de entrenamiento pero apenas 0.1705 sobre el conjunto de prueba, evidenciando un caso claro de overfitting. El Random Forest, al combinar 500 árboles mediante un esquema de ensamble, mitigó parcialmente este problema, alcanzando un R^2 de 0.3451 sobre el conjunto de prueba, superior al del árbol individual pero aún por debajo del modelo lineal. Los resultados permiten analizar no solamente el desempeño de los modelos, sino también el impacto de las decisiones relacionadas con la preparación de los datos, la partición aleatoria y el control de la complejidad sobre la capacidad de generalización de cada algoritmo.

I. PROBLEMÁTICA

El desempeño académico de los estudiantes puede estar relacionado con múltiples factores, entre los cuales se encuentran el tiempo dedicado al estudio, el porcentaje de asistencia, los hábitos de sueño y el rendimiento académico obtenido previamente. La identificación de relaciones entre estas características y el desempeño final puede resultar útil para comprender los patrones presentes en un conjunto de datos educativos.

Dado esta situación, se plantea un problema de regresión; cuya meta, es predecir la calificación obtenida por un estudiante en un examen final. La variable objetivo utilizada es *final_exam_score*, mientras que las variables predictoras corresponden a diferentes características académicas y personales.

Las características consideradas son las horas de estudio, el porcentaje de asistencia, las horas de sueño, la existencia de un trabajo de medio tiempo, la calificación previa, el

acceso a Internet y la participación en actividades extracurriculares.

II. DATOS

El conjunto de datos utilizado corresponde a Student Performance & Study Habits Dataset, disponible en Kaggle. El conjunto contiene información de 1,000 estudiantes y 12 variables relacionadas con características de los estudiantes, hábitos de estudio y desempeño académico.

La Tabla I presenta las variables disponibles en el conjunto de datos.

TABLE I
DESCRIPCIÓN DE LAS VARIABLES DEL CONJUNTO DE DATOS

Variable	Descripción
<i>student_id</i>	Identificador único
<i>gender</i>	Género
<i>study_time_hours</i>	Horas de estudio al día.
<i>attendance_percent</i>	Porcentaje de asistencia.
<i>sleep_hours</i>	Horas de sueño.
<i>parental_education</i>	Nivel educativo de los padres.
<i>internet_access</i>	Acceso a Internet.
<i>extracurricular_activities</i>	Participación en actividades extracurriculares.
<i>part_time_job</i>	Trabaja de medio tiempo.
<i>previous_grade</i>	Calificación previa.
<i>final_exam_score</i>	Puntaje del examen final.
<i>final_grade</i>	Clasificación final de la calificación.

Para la predicción se seleccionaron únicamente las variables relevantes para el problema de regresión. La variable *student_id* fue descartada debido a que funciona únicamente como identificador y no representa una característica asociada al desempeño académico.

Asimismo, las variables categóricas binarias *part_time_job*, *internet_access* y *extracurricular_activities* fueron transformadas a valores numéricos. La categoría “Yes” fue representada mediante el valor 1, mientras que “No” fue representada mediante el valor 0; esto usando una técnica parecida al one hot encoding pero para evitar crear otra columna únicamente se reemplazo.

De esta manera, el conjunto final utilizado para el modelo contiene siete variables predictoras y una variable objetivo: donde las características (X) corresponden a las horas de estudio, asistencia, horas de sueño, trabajo de medio tiempo, calificación previa, acceso a Internet y actividades extracurriculares.

La variable objetivo se define como:

$$y = \text{final_exam_score}. \quad (1)$$

La calificación final presenta un promedio de 83.54 puntos y una desviación estándar de 10.34 puntos, lo que nos ayuda a saber la distribución de nuestro dataset, podemos ir infiriendo algunas cosas, por ejemplo viendo que el promedio aritmético es de 83.54 puntos y su desviación es de 10.34 puntos, al menos el 68 % de los alumnos sacaron entre 73.2 y 93.88 lo que significa que la mayoría logro pasar el examen final.

Las horas de estudio presentan un promedio de 3.57 horas, mientras que el porcentaje promedio de asistencia es de 85.09 %. Por otra parte, las horas de sueño presentan un promedio de 6.80 horas y la calificación previa presenta un promedio de 69.74 puntos.

III. ETL

El proceso de extracción, transformación y carga fue realizado antes del entrenamiento de los modelos con el objetivo de obtener un conjunto de datos adecuado para la regresión.

Según el sitio de Microsoft el ETL es el proceso de extracción de los datos, transformarlos en el formato que necesitamos para usarlo en el modelo y Subirlo a nuestro servidor o base de datos (Extract Transform Load).

En primer lugar, se cargó el conjunto de datos y se realizó una inspección de sus características. Posteriormente, se eliminó la variable `student_id` que para el análisis no la necesitamos.

A continuación, se seleccionaron las siete variables predictoras y la variable `final_exam_score`. Las variables binarias fueron transformadas de categorías textuales a valores numéricos mediante una codificación binaria.

Es importante señalar que para el experimento no se utiliza: `gender`, `parental_education` ni `final_grade` como variables predictoras.

La exclusión de `final_grade` resulta especialmente importante debido a que representa una clasificación derivada del desempeño final. Utilizar esta variable para predecir `final_exam_score` podría introducir información directamente relacionada con la variable objetivo y producir una estimación optimista pero falsa.

Con el objetivo de evitar sesgos derivados del orden original de los registros en el archivo (ya sea porque vienen ordenados de forma ascendente o descendente), la partición del conjunto de datos en entrenamiento, validación y prueba se realizó mediante un muestreo aleatorio. Para ello se utilizó el método `sample(frac=1, random_state=42)` de Pandas, que reordena aleatoriamente la totalidad de las instancias del conjunto de datos, con una semilla fija para garantizar que se pueda repetir los resultados. Se dividió el dataset en las siguientes proporciones: 60 % de entrenamiento, 20 % de validación y 20 % de prueba.

III-A. Análisis exploratorio

Antes del entrenamiento se realizó una análisis visual de las relaciones existentes entre las variables predictoras y la calificación final que es nuestra variable a predecir.




Fig. 1. Relación entre las variables predictoras y la calificación del examen final.

La Figura 1 presenta los diagramas de dispersión correspondientes a las variables numéricas y binarias seleccionadas. Esto nos puede ayudar a ver que dado nuestros datos predictivos, una línea nos puede ayudar a explicar si bien no todos los datos, la mayoría de ellos si se pueden explicar, también podemos ir notando que las variables binarias a lo mejor no son indispensables en nuestro análisis.

En el caso de `study_time_hours`, se observa una tendencia positiva general entre las horas dedicadas al estudio y la calificación final. Los estudiantes que tienen un mayor número de horas de estudio tienden a concentrarse en valores superiores de `final_exam_score`. Sin embargo, la dispersión existente indica que esta variable no explica por sí sola toda la variabilidad observada.

El porcentaje de asistencia también presenta una tendencia positiva. Los estudiantes con un gran porcentaje de asistencia tienden a presentar calificaciones mayores, aunque existen observaciones con valores similares de asistencia y resultados académicos diferentes.

La relación entre `sleep_hours` y la calificación final presenta una dispersión considerable, lo cual dificulta establecer visualmente una relación lineal fuerte entre ambas variables. Esto podría deberse a que la cantidad de horas dormidas no necesariamente refleja la calidad del descanso; es posible que tanto la privación de sueño como el exceso también incidan negativamente en el rendimiento cognitivo. Adicionalmente, se observa una ligera tendencia no lineal, donde tanto muy pocas como demasiadas horas de sueño parecen asociarse con scores algo menores. Explorar esta relación en profundidad excede el alcance de este análisis, pero es una observación relevante para trabajo futuro."

Por otro lado, `previous_grade` presenta una relación visualmente más marcada con la calificación del examen final. Los estudiantes con calificaciones previas elevadas tienden a conseguir el mismo resultado nuevamente en `final_exam_score`. Esta característica puede resultar especialmente relevante




Fig. 2. Frecuencia de las variables predictoras y la calificación del examen final.

para la predicción.

Las variables binarias muestran distribuciones de calificaciones en ambas categorías. En particular, los estudiantes con y sin trabajo de medio tiempo presentan un rango amplio de calificaciones, por lo que esta característica no parece explicar de manera aislada el desempeño final.

En conjunto, el análisis exploratorio sugiere que la calificación final depende de una combinación de características y no de una única variable. Esta observación justifica el uso de un modelo multivariable de regresión.

La Figura 2 presenta los histogramas de las variables que estamos considerando para pasarle al modelo, este gráfico nos ayuda a observar la frecuencia de los datos y también podemos ir viendo si contamos con un outlier que nos pueda sesgar los datos. De aquí podemos ir sacando varios datos interesantes para este estudio.

El primero, viendo la parte de `study_time_hours`, podemos observar que la mayoría de estudiantes le dedican un total de casi 4 horas en promedio, donde también una gran parte le dedica 2 horas o menos y muy pocos le dedican más de 6 horas.

En cuanto a `attendance_percent`, la distribución está sesgada hacia la derecha: la mayoría de los estudiantes se concentran entre 80% y 100% de asistencia, con muy pocos casos por debajo del 60%. Esto sugiere que el grupo estudiado tiene, en general, buenos niveles de asistencia, y que los valores bajos son la excepción más que la norma.

La variable `sleep_hours` presenta una distribución aproximadamente simétrica y con forma de campana, centrada alrededor de 6 a 7 horas de sueño, lo cual es consistente con patrones de sueño típicos reportados en la literatura. Existen pocos casos en los extremos (menos de 4 horas o más de 9

horas), por lo que no se observan outliers preocupantes en esta variable.

Continuando con las variables binarias, `part_time_job` muestra que aproximadamente dos tercios de los estudiantes no tienen un trabajo de medio tiempo, mientras que el resto sí. Por otro lado, `internet_access` está fuertemente desbalanceada: la gran mayoría de los estudiantes cuentan con acceso a internet, y solo una fracción pequeña no lo tiene. En el caso de `extracurricular_activities` muestra que una mayoría de los estudiantes participa en actividades extracurriculares, aunque existe una gran parte que no participa en este tipo de actividades.

La variable `previous_grade` presenta una distribución aproximadamente normal, centrada alrededor de 70 puntos, con un rango que va de 30 a 100 puntos. No se observan outliers evidentes que puedan sesgar el análisis.

Finalmente, `final_exam_score`, nuestra variable objetivo, muestra una distribución sesgada, con la mayoría de valores concentrados principalmente entre 80 y 100 puntos, con un pico notable en el valor máximo (100). Esto puede ocasionar problemas al momento de hacer predicciones: dado que la mayoría de los datos se concentran en calificaciones altas, el modelo contará con suficiente información para predecir bien notas de 80 en adelante, pero tendrá un desempeño más pobre prediciendo calificaciones bajas, ya que no cuenta con suficientes datos de entrenamiento en ese rango.

La Figura 3 presenta la matriz de correlación entre las variables consideradas para el modelo y la variable a predecir, `final_exam_score`. Este gráfico nos permite observar qué tan relacionadas linealmente están las variables entre sí, con valores que van de -1 (correlación negativa perfecta) a 1 (correlación positiva perfecta), donde valores cercanos a 0 indican poca o ninguna relación lineal. Lo que más nos interesa aquí es la relación de cada variable predictora con `final_exam_score`, mostrada en la última fila/columna de la matriz.

Tomando primero `study_time_hours`, observamos una correlación de 0.57 con la calificación final, la más alta entre todas las variables. Esto indica una relación lineal positiva moderada-fuerte: a mayor número de horas de estudio, existe una tendencia consistente de que la calificación final también sea mayor. Sin embargo, esto no implica una relación causal directa ni cuantifica el tamaño del efecto; solamente indica la fuerza de la asociación lineal entre ambas variables.

`previous_grade` presenta la segunda correlación más alta (0.41), lo cual es esperado: los estudiantes con mejor desempeño académico previo tienden a mantener un desempeño similar en el examen final.

`attendance_percent` (0.26) e `internet_access` (0.17) muestran correlaciones positivas más débiles, sugiriendo una relación lineal existente pero modesta con el desempeño en el examen.

`sleep_hours` (0.15) y `extracurricular_activities` (0.02) presentan correlaciones muy débiles, consistente con lo observado previamente en los diagramas de dispersión, donde estas variables no mostraban una tendencia lineal clara.

Un caso particular es `part_time_job`, con una correlación




Fig. 3. Matriz de correlación de Pearson entre las variables predictoras y la calificación del examen final.

negativa de -0.15, la única variable con relación negativa respecto a la calificación final. Esto sugiere que tener un trabajo de medio tiempo se asocia ligeramente con calificaciones más bajas, aunque la magnitud de esta relación es débil.

IV. MODELOS DE REGRESIÓN

Como primer experimento se implementó manualmente un modelo de regresión lineal utilizando el algoritmo de gradiente descendiente para la parte de optimización. El propósito de esta implementación fue comprender el proceso de aprendizaje de los parámetros sin utilizar directamente una implementación de regresión proporcionada por una biblioteca de aprendizaje automático.

La hipótesis utilizada por el modelo corresponde a una función lineal:

$$\hat{y}_i = \beta_0 + \sum_{j=1}^p \beta_j x_{ij}, \quad (2)$$

donde β_0 representa el término independiente (el valor predicho de $\hat{y}_i$ cuando todas las características son iguales a cero), p representa el número total de características utilizadas por el modelo, β_j corresponde al peso asociado a la característica j , x_{ij} representa el valor de la característica j para el estudiante i , y $\hat{y}_i$ corresponde a la calificación predicha.

Para facilitar el proceso de optimización y evitar problemas de convergencia en el gradiente descendiente, dado que las variables predictoras presentan escalas muy distintas entre sí (por ejemplo, valores de 0 a 10 en algunas variables y de 0 a 100 en otras), las variables predictoras fueron estandarizadas mediante la siguiente transformación:

$$x' = \frac{x_{ij} - \mu_j}{\sigma_j}, \quad (3)$$

donde x_{ij} es el valor original de la característica j para el estudiante i , μ_j es la media de la característica j a través de todos los estudiantes, σ_j es la desviación estándar de la característica j , y x' corresponde al valor estandarizado resultante, con media 0 y desviación estándar 1.

La función de costo utilizada corresponde a una variante del Error Cuadrático Medio (MSE, por sus siglas en inglés):

$$J(\theta, b) = \frac{1}{2m} \sum_{i=1}^m (\hat{y}_i - y_i)^2, \quad (4)$$

donde $\hat{y}_i$ es la predicción, y_i es el valor real, y m representa el número de observaciones utilizadas durante el entrenamiento.

El gradiente de los parámetros se calcula mediante:

$$\frac{\partial J}{\partial \theta} = \frac{1}{m} X^T (\hat{y} - y), \quad (5)$$

mientras que el gradiente correspondiente al término independiente está dado por:

$$\frac{\partial J}{\partial b} = \frac{1}{m} \sum_{i=1}^m (\hat{y}_i - y_i). \quad (6)$$

donde m es el número de observaciones utilizadas durante el entrenamiento, X es la matriz de características (de tamaño $m \times p$) y X^T es su transpuesta, utilizada para expresar de forma matricial la suma sobre todas las observaciones i del producto entre el error $(\hat{y}_i - y_i)$ y cada característica x_{ij} .

Los parámetros se actualizan utilizando:

$$\theta_{t+1} = \theta_t - \alpha \frac{\partial J}{\partial \theta}, \quad (7)$$

y

$$b_{t+1} = b_t - \alpha \frac{\partial J}{\partial b}, \quad (8)$$

donde α corresponde a la tasa de aprendizaje que para este experimento fue de 0.01.

IV-A. Partición de los datos

Con el objetivo de evaluar de manera más rigurosa la capacidad de generalización de los modelos, el conjunto de datos fue dividido en tres subconjuntos antes mencionados: entrenamiento, validación y prueba, compuestos por 600, 200 y 200 observaciones respectivamente.

El conjunto de entrenamiento fue utilizado exclusivamente para ajustar los parámetros de cada modelo (los coeficientes θ y b en el caso de la regresión lineal, y la estructura del árbol en los modelos basados en árboles). El conjunto de validación se reservó para monitorear el desempeño del modelo sobre datos no utilizados en el entrenamiento sin comprometer la evaluación final. Finalmente, el conjunto de prueba se mantuvo completamente aislado del proceso de entrenamiento y selección de modelo, utilizándose únicamente para reportar una estimación final del desempeño.

La estandarización de las variables (media 0, desviación estándar 1) se calculó en cada partición por separado para evitar fugas de datos.

IV-B. Convergencia del modelo de regresión multilíneal

Durante el entrenamiento se almacenaron los valores de la función de costo y del coeficiente de determinación R^2 en cada época. Estas variables permiten observar el comportamiento del algoritmo durante el proceso de optimización.

El comportamiento esperado es una disminución progresiva de la función de costo acompañada por un incremento del R^2 . Una vez que el modelo alcanza una región estable, las mejoras adicionales tienden a ser menores.

En este experimento, el algoritmo alcanzó el máximo de 5,000 épocas sin llegar al objetivo de $R^2 = 0.95$. El resultado obtenido sobre el conjunto de entrenamiento fue:

$$R_{\text{train}}^2 \approx 0.666. \quad (9)$$

Este resultado indica que el modelo lineal implementado manualmente logra explicar aproximadamente el 66.6 % de la variabilidad de la calificación final dentro del conjunto utilizado para el entrenamiento.

IV-C. Cambio de modelos

Como modelos adicionales se implementaron un DecisionTreeRegressor y posteriormente un RandomForestRegressor, utilizando exactamente el mismo conjunto de entrenamiento, validación y prueba que el modelo manual (los primeros 600 registros para entrenamiento, 200 para validación y los 200 restantes para prueba), ya estandarizados. De esta manera, la comparación entre los tres modelos se realiza bajo condiciones de datos idénticas.

Ambos modelos permiten representar relaciones no lineales mediante una estructura de decisiones basada en particiones sucesivas del espacio de características; el Random Forest, además, combina múltiples árboles mediante un esquema de ensamble con el objetivo de reducir la varianza respecto a un único árbol de decisión.

IV-C.1. Árbol de decisión:




Fig. 4. Evolución del R^2 durante las épocas de entrenamiento del gradiente descendente.




Fig. 5. Convergencia de la función de costo (MSE) durante las épocas de entrenamiento del gradiente descendente.

IV-C.1.a. Fundamento Matemático sobre Árbol de decisión de regresión: A diferencia del modelo de regresión lineal, cuya hipótesis asume una relación aditiva y lineal entre las variables predictoras y la variable objetivo, el árbol de decisión construye la predicción mediante una partición recursiva del espacio de características en regiones disjuntas.

Sea R una región del espacio de características que contiene un subconjunto de observaciones de entrenamiento. Dado un par formado por una variable predictora x_j y un umbral de corte s , el algoritmo divide R en dos regiones:

$$R_1(j, s) = \{x \mid x_j \leq s\}, \quad R_2(j, s) = \{x \mid x_j > s\}. \quad (10)$$

Para cada posible par (j, s) , el algoritmo calcula el valor promedio de la variable objetivo dentro de cada región resultante:

$$\bar{y}_{R_1} = \frac{1}{|R_1|} \sum_{i: x_i \in R_1} y_i, \quad \bar{y}_{R_2} = \frac{1}{|R_2|} \sum_{i: x_i \in R_2} y_i, \quad (11)$$

y selecciona el par (j, s) que minimiza la suma del error cuadrático dentro de ambas regiones:

$$\min_{j, s} \left[\sum_{i: x_i \in R_1(j, s)} (y_i - \bar{y}_{R_1})^2 + \sum_{i: x_i \in R_2(j, s)} (y_i - \bar{y}_{R_2})^2 \right]. \quad (12)$$

Este procedimiento se aplica de manera recursiva sobre cada región resultante, generando así una estructura jerárquica de particiones. En esta implementación, la recursión se detiene únicamente al alcanzar una profundidad máxima de 20 niveles, sin imponer una restricción sobre el número mínimo de observaciones por hoja, lo cual permite al árbol continuar dividiendo el espacio prácticamente hasta memorizar cada observación individual.

Una vez construido el árbol, la predicción para una nueva observación x se obtiene identificando la hoja R_m a la que pertenece dicha observación, tras recorrer las condiciones

de división desde la raíz, y asignando como predicción el promedio de la variable objetivo de las observaciones de entrenamiento contenidas en esa hoja:

$$\hat{y} = \bar{y}_{R_m} = \frac{1}{|R_m|} \sum_{i: x_i \in R_m} y_i. \quad (13)$$

Cabe señalar que, al tratarse de un problema de regresión, el criterio de división utilizado no corresponde a medidas de impureza basadas en teoría de la información (como la entropía o la ganancia de información), las cuales son propias de árboles de clasificación donde la variable objetivo es categórica. Al ser `final_exam_score` una variable continua, el criterio de división utilizado corresponde a la minimización del error cuadrático.

IV-C.1.b. Implementación: El árbol de decisión, configurado con una profundidad máxima de 20 niveles y sin restricción sobre el número mínimo de observaciones por hoja, obtuvo un desempeño perfecto sobre el conjunto de entrenamiento, con:

$$R^2_{\text{train}} = 1.00 \quad (14)$$

y un error cuadrático medio prácticamente igual a cero.

Sin embargo, este comportamiento no se mantuvo sobre los conjuntos de validación y prueba. El modelo obtuvo un R^2 de -0.0025 en validación y de 0.1705 en prueba, con un MSE de 89.67 y 85.20 respectivamente.

La diferencia entre el desempeño de entrenamiento y el de validación/prueba constituye una señal clara de overfitting. Al no imponer un mínimo de observaciones por hoja, el árbol continuó particionando el espacio de características hasta memorizar prácticamente cada observación individual del conjunto de entrenamiento, perdiendo con ello su capacidad de generalizar hacia observaciones que no fueron utilizadas para construir el modelo.

IV-C.2. Random Forest:

IV-C.2.a. Fundamento Matemático de Random Forest:

Un bosque aleatorio (random forest) es un método de ensamble que combina las predicciones de múltiples árboles de decisión, entrenados de forma independiente, con el objetivo de reducir la varianza del modelo sin incrementar significativamente su sesgo.

La construcción de cada árbol $b = 1, \dots, B$ que conforma el bosque se realiza mediante dos fuentes de aleatoriedad:

1. Bootstrap aggregating (bagging): Cada árbol se entrena utilizando una muestra obtenida mediante remuestreo con reemplazo del conjunto de entrenamiento original, del mismo tamaño que este último. Como consecuencia, cada árbol observa un subconjunto ligeramente distinto de las observaciones disponibles.
2. Selección aleatoria de características: En cada nodo, en lugar de evaluar todas las variables predictoras disponibles para encontrar la mejor división, el algoritmo considera únicamente un subconjunto aleatorio de ellas. Esto reduce la correlación entre los árboles individuales del bosque.

Cada árbol T_b se construye siguiendo exactamente el mismo criterio de minimización de error cuadrático. La predicción final del bosque para una observación x se obtiene promediando las predicciones individuales de los B árboles:

$$\hat{y}(x) = \frac{1}{B} \sum_{b=1}^B T_b(x). \quad (15)$$

Este promedio es el mecanismo mediante el cual el bosque aleatorio reduce la varianza respecto a un único árbol. Formalmente, si cada árbol $T_b(x)$ tuviera varianza σ^2 y las predicciones fueran independientes entre sí, la varianza del promedio sería:

$$\text{Var} \left(\frac{1}{B} \sum_{b=1}^B T_b(x) \right) = \frac{\sigma^2}{B}. \quad (16)$$

En la práctica, los árboles no son completamente independientes (ya que comparten el mismo conjunto de datos original y, en algunos casos, las mismas variables candidatas en ciertas divisiones), por lo que la reducción real de varianza es menor a la ideal, pero sigue siendo sustancial cuando B es grande, como en este caso ($B = 500$).

En este experimento, el bosque fue configurado con $B = 500$ árboles (`n_estimators`) y un máximo de 200 nodos hoja por árbol (`max_leaf_nodes`). Esta última restricción limita la profundidad efectiva de cada árbol individual del bosque, aunque, como se observa más adelante, no es suficientemente restrictiva para eliminar por completo el sobreajuste de cada árbol individual.

IV-C.2.b. Implementación: El Random Forest, configurado con 500 árboles y un máximo de 200 nodos hoja por árbol, obtuvo los siguientes resultados:

$$R^2_{\text{train}} = 0.9173, \quad R^2_{\text{val}} = 0.0601, \quad R^2_{\text{test}} = 0.3451 \quad (17)$$

con un MSE de 6.65, 49.01 y 41.50 respectivamente.

Al igual que el árbol individual, el Random Forest presenta una brecha considerable entre su desempeño de entrenamiento y el de validación/prueba, lo cual indica que también incurre en Overfitting. Sin embargo, este overfitting es menos severo que el observado en el árbol individual: el R^2 de entrenamiento no llega a ser perfecto (0.9173 en lugar de 1.00) y, más importante aún, el R^2 de prueba (0.3451) duplica prácticamente al obtenido por el árbol individual (0.1705). Esta mejora es consistente con el mecanismo de ensamble del bosque aleatorio: al promediar las predicciones de 500 árboles entrenados sobre distintas muestras (aplicando Bootstrapping), la varianza asociada a las particularidades de un único árbol se reduce considerablemente, aunque no se elimina por completo, dado que cada árbol individual del bosque conserva una capacidad considerable para ajustarse al ruido de su propia muestra de entrenamiento.

Este resultado también permite observar que un modelo con un R^2 de 1.0 sobre entrenamiento no necesariamente es el modelo más adecuado, y que combinar múltiples modelos mediante un ensamble puede mitigar, aunque no resolver por

completo, el problema de overfitting. Para evaluar un modelo predictivo es necesario analizar principalmente su desempeño sobre datos no utilizados durante el entrenamiento.

IV-D. Análisis del cambio realizado

La comparación entre las tres implementaciones permite identificar varias diferencias metodológicas, más allá de únicamente el algoritmo utilizado.

El modelo manual, basado en gradiente descendiente, proporciona un mayor control y conocimiento sobre lo que está pasando, debido a que fue programado manualmente. Esto permite observar directamente el proceso mediante el cual el algoritmo minimiza la función de pérdida.

Por su parte, tanto el DecisionTreeRegressor como el RandomForestRegressor simplifican considerablemente el proceso de entrenamiento del modelo al utilizar implementaciones optimizadas proporcionadas por Scikit-learn, sin necesidad de definir manualmente ninguna función de optimización.

A diferencia del modelo manual, cuya hipótesis asume una relación estrictamente lineal entre las características y la variable objetivo, ambos modelos basados en árboles son capaces de representar relaciones no lineales mediante particiones sucesivas del espacio de características. Sin embargo, esta mayor flexibilidad también incrementa el riesgo de sobreajuste, tal como se observó de forma extrema en el árbol de decisión individual y de forma más moderada en el Random Forest.

La diferencia de desempeño entre el árbol individual y el Random Forest ilustra además el valor de los métodos de ensamble: al combinar múltiples árboles entrenados sobre distintas muestras y promediar sus predicciones, el Random Forest logra reducir la varianza del modelo sin modificar sustancialmente su sesgo, obteniendo un desempeño intermedio entre el árbol individual (más flexible pero más inestable) y el modelo lineal (más simple pero más estable).

Es importante señalar que los tres modelos fueron entrenados y evaluados utilizando exactamente el mismo conjunto de entrenamiento, el mismo conjunto de validación, el mismo conjunto de prueba y el mismo procedimiento de escalamiento. Por lo tanto, la diferencia de desempeño observada puede atribuirse directamente a la naturaleza de cada algoritmo y a sus respectivos hiperparámetros, y no a diferencias en la preparación de los datos.

V. RESULTADOS

En este trabajo se estudió el problema de predicción de la calificación obtenida en un examen final a partir de características relacionadas con los hábitos de estudio y el desempeño académico previo de los estudiantes.

Se implementó inicialmente un modelo de regresión lineal mediante gradiente descendiente de forma manual. Esta implementación permitió controlar directamente la función de hipótesis, la función de costo, el cálculo de los gradientes y la actualización de los parámetros. El modelo manual alcanzó un R^2 de aproximadamente 0.6656 sobre el conjunto de entrenamiento después de 5,000 épocas. Al evaluar sus predicciones sobre el conjunto de prueba, obtuvo un MSE

de 35.60 y un R^2 de 0.6455, resultado consistente con el obtenido sobre el conjunto de validación ($R^2 = 0.6320$).

Como segundo modelo se implementó un DecisionTreeRegressor, utilizando exactamente el mismo conjunto de entrenamiento, validación, prueba y procedimiento de escalamiento que el modelo manual. Este modelo alcanzó un R^2 de 1.00 sobre los datos de entrenamiento, pero obtuvo un R^2 de apenas -0.0025 sobre el conjunto de validación y de 0.1705 sobre el conjunto de prueba. Esta diferencia evidencia un problema severo de overfitting y demuestra la importancia de evaluar los modelos utilizando datos no vistos durante el entrenamiento.

Como tercer modelo se implementó un RandomForestRegressor compuesto por 500 árboles, bajo las mismas condiciones de datos que los modelos anteriores. Este modelo alcanzó un R^2 de 0.9173 sobre el conjunto de entrenamiento, 0.0601 sobre validación y 0.3451 sobre prueba. Si bien el Random Forest también presenta evidencia de overfitting, su desempeño sobre datos no vistos resultó superior al del árbol de decisión individual, lo cual confirma que el mecanismo de ensamble logra reducir parcialmente la varianza del modelo.

La Tabla II resume el R^2 obtenido por los tres modelos sobre el conjunto de prueba.

TABLE II
RESUMEN DEL R^2 DE PRUEBA OBTENIDO POR CADA MODELO

Modelo	R^2 prueba
Regresión lineal (manual, gradiente descendiente)	0.6455
Árbol de decisión (Scikit-learn)	0.1705
Random Forest (Scikit-learn, 500 árboles)	0.3451

En conclusión, el experimento muestra que la implementación manual de un algoritmo de regresión lineal permite comprender con mayor profundidad el proceso de optimización, y en este caso particular obtuvo el mejor desempeño sobre datos no vistos entre los tres modelos evaluados. Los modelos basados en árboles, si bien poseen una mayor capacidad para representar relaciones no lineales, resultaron más propensos al sobreajuste bajo la configuración de hiperparámetros utilizada; el Random Forest logró mitigar parcialmente este problema respecto al árbol individual, pero no logró superar al modelo lineal. Esto ilustra que un modelo con mayor capacidad de representación no necesariamente generaliza mejor, dependiendo de los patrones de los datos un modelo complejo puede no ser la mejor solución al problema.

REFERENCES

- [1] H. Patil, "Student Performance & Study Habits Dataset," Kaggle.
- [2] C. Siemens, "Extract, transform, and load (ETL)," Microsoft Learn, Azure Architecture Center. [Online]. Available: <https://learn.microsoft.com/en-us/azure/architecture/data-guide/relational-data/etl> [Accessed: Aug. 30, 2026].
- [3] Majdalani, J. (2024, septiembre 16). ¿Es malo dormir más de 8 horas? Esto dicen los expertos. El Independiente. <https://www.elindependiente.com/tendencias/2024/09/16/es-malo-dormir-mas-8-horas-expertos/>